

研究定位

本研究聚焦於 ICU 病患惡化早期預警模型之建立。研究核心並非單純將 Fuzzy Neural Network 應用於疾病分類，也不是建立完整的 Clinical Decision Support System，而是提出一個可作為臨床決策支援系統核心模組的本質可解釋早期預警模型。

本研究主軸為：

Early Warning Prediction + Intrinsic Explainability + Expert-Knowledge-Guided Temporal Fuzzy Neural Network

其中，Clinical Decision Support、Trustworthy AI、Responsible AI 與 Neuro-Symbolic AI 作為研究背景與理論延伸；本研究主要實作重點則聚焦於：

1. 以明確 Outcome 定義 ICU 病患惡化事件
2. 將 NEWS2 / SOFA 等臨床知識轉化為 FNN 的初始知識
3. 建立 Clinical Consistency Regularization
4. 產生可解釋的 IF-THEN temporal fuzzy rules
5. 定義 Rule Evaluation Framework 量化規則品質

一、研究背景與動機

加護病房（Intensive Care Unit, ICU）病患的生理狀態具有高度動態性與時間相依性。病患惡化通常不是由單一時間點的異常數值所造成，而是多項生命徵象、實驗室檢驗數據與器官功能指標在數小時內逐漸變化的結果。因此，若能在病患真正惡化前 6、12 或 24 小時提前偵測風險，對於重症照護、醫療資源配置與臨床決策支援具有重要價值。

近年來，許多機器學習與深度學習模型已被應用於 ICU mortality prediction、sepsis prediction、hemodynamic deterioration prediction 以及 patient deterioration prediction。這些模型雖然在 AUROC、AUPRC 等預測效能指標上已有良好表現，但多數方法仍屬於黑盒模型。若模型只能輸出「病患未來 12 小時內惡化風險為 87%」，但無法說明該判斷是基於哪些生理變化或臨床規則，醫療人員仍難以完全信任並採用模型結果。

目前許多醫療 AI 研究使用 SHAP、LIME 等事後解釋方法提供特徵重要性分析。然而，此類 post-hoc explanation 通常只能指出哪些特徵影響模型輸出，未必能呈現

模型內部完整推理過程，也無法保證模型推論符合臨床常識。例如，SHAP 可以指出 SpO₂ 是重要特徵，但不一定能產生醫師容易理解的 IF-THEN 規則。

相較之下，Fuzzy Neural Network (FNN) 結合模糊邏輯的規則推理能力與神經網路的資料學習能力，具有發展本質可解釋醫療 AI 的潛力。FNN 可將連續生理數值轉換為臨床語意，例如「血氧偏低」、「呼吸速率偏高」、「血壓下降」，並進一步形成 IF-THEN 規則：

IF SpO₂ is low
AND respiratory rate is increasing
AND systolic blood pressure is decreasing
THEN deterioration risk is high.

然而，傳統 FNN 或 Neuro-Fuzzy 系統多採用隨機初始化方式建立 membership functions 與 fuzzy rules，導致模型在訓練初期缺乏臨床知識基礎，可能產生「數學上合理，但臨床上不合理」的規則。

因此，本研究提出一個 Knowledge-Guided Temporal Fuzzy Neural Network，將 NEWS2、SOFA 等臨床評分標準轉化為 membership functions、rule priors 與 clinical constraints，使模型在資料驅動學習前即具備臨床邏輯基礎，並透過時間特徵描述病患惡化軌跡，最終輸出病患惡化風險與可解釋的 IF-THEN temporal fuzzy rules。

二、病患惡化事件定義

將 ICU patient deterioration 明確定義為：未來 6、12 或 24 小時內 SOFA Score Increase ≥ 2 ，聚焦於病患器官功能是否在未來短時間內出現明顯惡化。

選擇 SOFA Score Increase ≥ 2 作為主要 Outcome 的原因如下：

1. SOFA 分數可反映 ICU 病患器官功能狀態
2. SOFA Score Increase ≥ 2 具有明確臨床意義
3. Outcome 定義較單純，適合建立可執行研究設計
4. 較容易與既有 ICU deterioration 或 organ dysfunction 研究比較
5. 與本研究使用 SOFA 作為 expert knowledge source 的方法設計一致

本研究將使用過去一段觀察視窗內的病患資料，預測未來 (H) 小時內是否發生 SOFA 分數上升至少 2 分，其中：

$$[H \in \{6, 12, 24\}]$$

對於病患 (i) 在時間點 (t) 的樣本，其標籤定義如下：

$$[Y_{i,t}^H = \begin{cases} 1, & \text{if } \max_{\tau \in (t, t+H]} \text{SOFA}_{i,\tau} - \text{SOFA}_{i,t} \geq 2 \\ 0, & \text{otherwise} \end{cases}]$$

其中：

- $(Y_{i,t}^H)$ ：病患 (i) 在時間 (t) 對應預測視窗 (H) 的惡化標籤
- $(\text{SOFA}_{i,t})$ ：病患 (i) 在時間 (t) 的 SOFA score
- (H)：預測時間範圍，包含 6、12、24 小時

Composite deterioration event 可作為未來延伸或 secondary analysis，但本研究主要模型建立與評估將以 SOFA Score Increase ≥ 2 為核心 Outcome。

三、Research Gap 分析

根據目前文獻整理與教授建議，本研究歸納出以下三個主要研究缺口。

Gap 1：現有 ICU 預測模型多依賴事後解釋，缺乏本質可解釋推理機制

目前許多 ICU 病患惡化預測、敗血症預測與死亡率預測研究使用 XGBoost、Random Forest、LightGBM、LSTM、GRU、Transformer 等模型。這些模型雖然能達到良好的預測效能，但多數屬於黑盒模型，臨床人員難以理解模型如何推理出病患高風險。

為提升模型透明度，現有研究常使用 SHAP、LIME 等 post-hoc explanation 方法。然而，這類方法大多提供 feature importance，無法直接產生醫師熟悉的 IF-THEN decision rules，也無法保證模型推理過程符合臨床邏輯。

因此，目前仍缺乏一種能直接提供本質可解釋推理機制的 ICU 病患惡化早期預警模型。

Gap 2：傳統 Fuzzy Neural Network 缺乏臨床知識初始化機制

Fuzzy Neural Network 具有規則推理與語意表示能力，適合處理醫療資料中的模糊性與不確定性。然而，多數 FNN 或 Neuro-Fuzzy 系統仍採用 random initialization 初始化 membership functions 與 fuzzy rules。

這會造成兩個問題：

第一，模型訓練初期缺乏醫學知識基礎，可能導致訓練不穩定或收斂至不理想的局部解。

第二，模型可能學出臨床上不合理的規則，例如血氧持續下降，但模型卻降低惡化風險。

因此，如何將 NEWS2、SOFA 等臨床知識轉化為 FNN 的 membership functions、rule priors 與 clinical constraints，是本研究的重要缺口。

Gap 3：現有可解釋模型較少描述病患惡化的時間軌跡

ICU 病患惡化通常是一個動態過程，而非單一時間點異常。例如，SpO₂ 持續下降、respiratory rate 逐漸上升、blood pressure 在數小時內逐步降低，往往比單一數值更能反映病患狀態變差。

然而，許多傳統 clinical scores 或靜態可解釋模型主要依賴單一時間點特徵，較難描述「持續下降」、「快速上升」、「異常持續時間」、「異常測量頻率」等時序型臨床概念。

因此，本研究希望將 temporal feature extraction 與 fuzzy rule reasoning 結合，使模型能產生具有時間語意的 IF-THEN temporal fuzzy rules。

四、研究問題

本研究提出以下四個研究問題：

RQ1 : Outcome-focused Early Warning

如何利用 ICU 病患的時序生理特徵，預測其在未來 6、12、24 小時內是否發生 SOFA Score Increase ≥ 2 的器官功能惡化？

RQ2 : Knowledge-Guided Initialization

如何將 NEWS2、SOFA 等臨床評分標準轉化為 Temporal Fuzzy Neural Network 的 membership functions、rule priors 與 clinical constraints？

RQ3 : Clinical Consistency Regularization

Clinical Consistency Regularization 是否能改善模型校準度，並降低臨床上不合理的預測或規則？

RQ4 : Rule Evaluation Framework

本研究提出之規則評估框架是否能量化 temporal fuzzy rules 的複雜度、穩定性、臨床一致性與規則漂移程度？

五、系統架構

本研究之系統架構可分為八個主要模組。

1. ICU Time-Series Data Input

本研究預計使用公開 ICU 資料庫，例如 MIMIC-IV 與 eICU。資料內容包含生命徵象、實驗室檢驗數據、器官功能相關指標、意識狀態、氧氣支持與治療介入紀錄。

候選變數包含：

- Heart rate
- Respiratory rate
- SpO₂
- Systolic blood pressure
- Mean arterial pressure
- Temperature

- Glasgow Coma Scale
 - Urine output
 - Creatinine
 - Bilirubin
 - Platelet count
 - Lactate
 - Oxygen support indicators
-

2. Outcome Label Construction

根據 SOFA Score Increase ≥ 2 定義建立標籤。對每個預測時間點 (t)，計算病患在未來 6、12、24 小時內 SOFA 分數是否上升至少 2 分，作為 binary classification label。

3. Sliding Window Preprocessing

病患資料將被轉換為時間滑動視窗樣本。每一筆樣本使用過去一段觀察視窗內的病患資料，例如過去 4、6 或 12 小時，預測未來 6、12 或 24 小時內是否發生惡化事件。

此階段包含：

- Irregular time-series alignment
- Missing value imputation
- Feature normalization
- Leakage-free preprocessing
- Train / validation / test split

其中，leakage-free preprocessing 將避免使用預測時間點之後才出現的資訊。

4. Temporal Feature Extraction

本研究不僅使用單一時間點數值，也將萃取可描述病患狀態變化的 temporal features，例如：

- Current value
- Moving average
- Maximum value
- Minimum value
- Standard deviation

- Slope
- Short-term change
- Abnormal duration
- Frequency of abnormal measurements

例如，對 SpO_2 不只記錄目前數值，也記錄過去 4 小時是否持續下降；對 respiratory rate 不只記錄目前數值，也記錄其是否逐漸上升。

5. Clinical Knowledge Transformation

本研究將 NEWS2、SOFA 等臨床評分標準轉化為三類模型知識：

1. Membership Function Initialization
2. Rule Prior Initialization
3. Clinical Consistency Constraints

這些知識將作為模型初始化與訓練約束，使 FNN 在資料學習前即具備臨床邏輯基礎。

6. Guideline-Guided Fuzzification Layer

此層會將連續生理數值轉換為 fuzzy linguistic terms，例如：

- SpO_2 : normal、low、critically low
- Heart rate : low、normal、high、very high
- Respiratory rate : normal、high、very high
- Blood pressure : normal、low、critically low
- Lactate : normal、high、very high

不同於傳統 FNN 隨機初始化，本研究將使用 NEWS2 / SOFA 的臨床級距初始化 fuzzy membership functions 的中心值與邊界。

7. Temporal Fuzzy Neural Network Optimization

模型將透過 FNN 架構學習 membership function parameters、rule weights 與最終風險輸出。訓練過程中將加入 Clinical Consistency Regularization，使模型在資料驅動學習的同時，避免學出明顯違反醫學常識的規則。

8. Risk Prediction and Rule Extraction

模型最終輸出兩種結果：


1. 病患在未來 6、12、24 小時內發生 SOFA Score Increase ≥ 2 的風險機率
2. 對應的 IF-THEN temporal fuzzy rules

例如：

IF SpO₂ is low
AND SpO₂ is continuously decreasing over the past 4 hours
AND respiratory rate is high
THEN deterioration risk is high.

或：

IF systolic blood pressure is decreasing
AND lactate is high
AND urine output is low
THEN deterioration risk is very high.



六、Fuzzy Neural Network Design Concept

FNN 設計概念

本研究提出之模型以 Fuzzy Neural Network 為基礎，並加入 temporal feature representation，使模型能同時考量病患目前狀態與短期變化趨勢。

整體模型可分為以下幾層。

1. Input Layer

輸入層包含病患的 clinical variables 與 temporal features。

State-based features 包含目前生理狀態，例如：

- Current heart rate
- Current SpO₂
- Current respiratory rate
- Current systolic blood pressure
- Current creatinine
- Current lactate

Trend-based features 包含短期變化，例如：

- Heart rate slope
- SpO₂ decreasing trend
- Blood pressure decreasing trend
- Abnormal respiratory rate duration
- Lactate increasing trend
- Urine output decreasing trend

2. Fuzzification Layer

此層將連續數值轉換為模糊語意。例如：

- SpO₂ = 88% → low SpO₂
- Heart rate = 132 bpm → very high heart rate
- SBP = 85 mmHg → low blood pressure
- Lactate = 4 mmol/L → high lactate

本研究將使用 NEWS2 / SOFA 等臨床評分標準初始化 membership functions，使 fuzzy sets 一開始就具有臨床意義。

3. Rule Layer

Rule layer 負責形成 IF-THEN fuzzy rules。

例如：

IF SpO₂ is low
AND respiratory rate is increasing
THEN deterioration risk is high.

或：

IF creatinine is high
AND urine output is low
THEN organ dysfunction risk is high.

Rule layer 將根據 clinical rule priors 建立初始規則，並在訓練過程中透過 ICU 真實資料調整 rule weights。

4. Neural Optimization Layer

此層負責更新 membership function parameters、rule weights 與最終預測輸出，使模型可從 ICU time-series data 中學習病患惡化模式。

與傳統 FNN 不同，本研究將透過 Clinical Consistency Regularization 限制模型，避免模型完全自由地由資料學習出臨床上不合理的規則。

5. Output Layer

輸出層產生病患惡化風險機率：

- Risk within 6 hours
- Risk within 12 hours
- Risk within 24 hours

並同步輸出觸發之主要 temporal fuzzy rules，作為模型的本質可解釋結果。

七、專家知識整合策略

本研究所稱之 expert knowledge，並非依賴個別醫師主觀經驗，而是指客觀、可計算、且已被臨床廣泛使用的評分標準與醫療指引，例如 NEWS2 與 SOFA。

本研究將 expert knowledge 整合至 FNN 的三個層次。

1. Membership Function Initialization

傳統 FNN 通常隨機初始化 membership functions。本研究將改以 NEWS2 / SOFA 中的臨床風險級距初始化 fuzzy membership functions。

例如，Heart rate 可以初始化為：

- Low heart rate
- Normal heart rate
- High heart rate
- Very high heart rate

SpO₂ 可以初始化為：

- Normal oxygen saturation
- Low oxygen saturation
- Critically low oxygen saturation

此設計可使模型第一層的 fuzzy linguistic terms 具有臨床基礎，而非單純由隨機參數決定。

2. Rule Prior Initialization

除了 membership functions，本研究也將 clinical scoring logic 轉化為 initial fuzzy rules。

例如：

IF SpO₂ is low
AND respiratory rate is high
THEN deterioration risk is high.

IF systolic blood pressure is low
AND consciousness level is abnormal
THEN deterioration risk is high.

IF creatinine is high
AND urine output is low
THEN organ dysfunction risk is high.

這些規則將作為 model rule priors，後續再透過資料學習調整權重。

3. Clinical Constraints

本研究將根據臨床高度共識的方向性知識建立 constraints。例如：

- SpO₂ 異常程度增加時，惡化風險不應不合理下降
- Blood pressure 異常程度增加時，惡化風險不應不合理下降
- Lactate 異常程度增加時，惡化風險不應不合理下降
- Creatinine 或 urine output 顯示腎功能惡化時，模型不應將其視為低風險訊號

這些 constraints 將進一步轉化為 Clinical Consistency Regularization。

八、臨床一致性正則化

本研究提出 Clinical Consistency Regularization，用於降低模型產生臨床上不合理預測或規則的可能性。

由於許多生理變數並非單純越高越危險，例如 heart rate 太高或太低都可能代表風險，因此本研究不直接對原始數值施加單調限制，而是先將臨床變數轉換為 Clinical Abnormality Score。

令：

$$[a_{i,j,t}]$$

表示病患 (i) 在時間 (t) 針對變數 (j) 的臨床異常程度分數。此分數可根據 NEWS2、SOFA 或臨床門檻轉換而來。

令模型預測風險為：

$$[\hat{y}_{i,t}]$$

臨床異常程度變化定義為：

$$[\Delta a_{i,j,t} = a_{i,j,t} - a_{i,j,t-\Delta t}]$$

模型預測風險變化定義為：

$$[\Delta \hat{y}_{i,t} = \hat{y}_{i,t} - \hat{y}_{i,t-\Delta t}]$$

若某個臨床異常程度增加，即：

$$[\Delta a_{i,j,t} > 0]$$

但模型預測風險下降，即：

$$[\Delta \hat{y}_{i,t} < 0]$$

則代表模型可能違反臨床一致性。因此，本研究定義 Clinical Consistency Loss 如下：

$$[\mathcal{L}_{cons} = \frac{1}{N} \sum_{i=1}^N \sum_{j \in \mathcal{K}} w_j \cdot \max(0, \Delta a_{i,j,t}) \cdot \max(0, -\Delta \hat{y}_{i,t})]$$

其中：

- (N)：樣本數
- ($\mathcal{K}$)：被納入臨床一致性限制的變數集合
- (w_j)：變數 (j) 的臨床重要性權重
- ($\Delta a_{i,j,t}$)：臨床異常程度變化
- ($\Delta \hat{y}_{i,t}$)：模型預測風險變化

此 loss 的意義是：

當臨床異常程度變嚴重時，模型風險不應不合理下降。若發生此情況，模型將受到懲罰。

模型總 Loss Function 定義如下：

[
 $\mathcal{L}_{total}$

$\mathcal{L}_{pred}$
+
 $\lambda_{cons} \mathcal{L}_{cons}$
+
 $\lambda_{sparse} \mathcal{L}_{sparse}$
]

其中：

- ($\mathcal{L}_{pred}$)：主要預測 loss，例如 binary cross entropy
- ($\mathcal{L}_{cons}$)：臨床一致性正則化
- ($\mathcal{L}_{sparse}$)：規則稀疏化 loss，用於避免模型產生過多或過長規則
- (λ_{cons})：控制 clinical consistency loss 強度
- (λ_{sparse})：控制 rule sparsity loss 強度

此設計使模型能在預測效能、臨床一致性與規則簡潔性之間取得平衡。

九、Rule Evaluation Framework

規則評估框架

本研究不僅評估模型的預測效能，也將建立一套規則評估框架，用於量化 IF-THEN temporal fuzzy rules 是否具有解釋性、穩定性與臨床合理性。

本研究將定義四個主要規則評估指標：

1. Rule Complexity
2. Rule Stability
3. Rule Concordance
4. Rule Drift

1. Rule Complexity

Rule Complexity 用於衡量模型萃取出規則是否過於複雜。

假設模型共萃取出 (K) 條有效規則，第 (k) 條規則的 antecedents 集合為 (A_k)，則 Rule Complexity 定義為：

$$\left[\begin{array}{l} \text{RuleComplexity} = \\ \frac{1}{K} \sum_{k=1}^K |A_k| \end{array} \right]$$

其中：

- (K)：有效規則數量
- (|A_k|)：第 (k) 條規則中的 IF 條件數量

例如：

IF SpO₂ is low
AND RR is high
AND SBP is decreasing
THEN risk is high.

此規則的 antecedents 數量為 3。

Rule Complexity 越低，代表規則越簡潔，臨床人員越容易理解。

2. Rule Stability

Rule Stability 用於衡量模型在不同資料切分、cross-validation 或 bootstrap samples 下，萃取出規則是否一致。

假設第 (p) 次訓練得到的 Top-K 規則集合為：

$$\left[\begin{array}{l} R^{\{p\}} \end{array} \right]$$

第 (q) 次訓練得到的 Top-K 規則集合為：

$$\left[\begin{array}{l} R^{\{q\}} \end{array} \right]$$

則可使用 Jaccard Similarity 衡量規則集合相似度：

$$[\\begin{aligned} J(R^{\{p\}}, R^{\{q\}}) = & \\frac{|R^{\{p\}} \cap R^{\{q\}}|}{|R^{\{p\}} \cup R^{\{q\}}|} \\ & \\ \end{aligned}]$$

若共有 (M) 次訓練，整體 Rule Stability 定義為：

$$[\\begin{aligned} \\text{RuleStability} = & \\frac{2}{M(M-1)} \\ & \\sum_{p < q} \\ & \\frac{|R^{\{p\}} \cap R^{\{q\}}|}{|R^{\{p\}} \cup R^{\{q\}}|} \\ & \\ \end{aligned}]$$

Rule Stability 越高，代表模型萃取出的規則越穩定，不是由單一資料切分造成的偶然結果。

3. Rule Concordance

Rule Concordance 用於衡量模型萃取出的規則是否符合臨床知識，例如 NEWS2、SOFA 或基本醫學邏輯。

對於第 (k) 條規則 (r_k)，定義其 clinical alignment score 為：

$$[\\begin{aligned} C(r_k) = & \\frac{\\text{number of clinically consistent antecedents in } r_k}{\\text{number of antecedents in } r_k} \\ & \\ \end{aligned}]$$

整體 Rule Concordance 定義為：

$$[\\begin{aligned} \\text{RuleConcordance} = & \\frac{1}{K} \\ & \\sum_{k=1}^K \\ & \\end{aligned}]$$

C(r_k)
]

例如：

IF SpO₂ is low
AND respiratory rate is increasing
THEN deterioration risk is high.

此規則與臨床知識一致，因此具有較高 concordance。

相反地，若模型產生：

IF SpO₂ is low
THEN deterioration risk is low.

此規則明顯違反臨床邏輯，因此 concordance 較低。

Rule Concordance 越高，代表模型規則越符合臨床知識。

4. Rule Drift

Rule Drift 用於衡量模型訓練後的 fuzzy membership functions 與 initial clinical-guided settings 之間的偏離程度。

令初始臨床知識引導之 membership function 參數為：

[
\theta_0
]

訓練後模型學得的 membership function 參數為：

[
\theta
]

則 Rule Drift 定義為：

[
RuleDrift =
\frac{
|\theta - \theta_0|_2

```
}{  
|\theta_0|_2 + \epsilon  
}  
]
```

其中：

- (θ_0) ：初始臨床指引參數
- (θ) ：訓練後模型參數
- (ϵ) ：避免分母為 0 的極小常數

Rule Drift 並非越低越好。其解讀如下：

- Drift 過低：模型可能只是複製臨床評分，資料學習能力不足
- Drift 適中：模型能根據 ICU 真實資料調整臨床知識
- Drift 過高：模型可能偏離臨床邏輯，降低可解釋性

因此，本研究將同時觀察 Rule Drift 與 Rule Concordance，以分析模型是否能在資料學習與臨床一致性之間取得平衡。

十、Baseline Models

比較基準模型

本研究將與四類 baseline models 進行比較。

1. Clinical Score Baselines

此類模型代表傳統臨床評分系統。

- NEWS2 Score
- SOFA Score

比較目的：

評估本研究模型是否能在保留臨床可解釋性的同時，優於傳統手工評分系統。

2. Interpretable Machine Learning Baselines

此類模型代表傳統可解釋或半可解釋機器學習方法。

- Logistic Regression
- Decision Tree
- Generalized Additive Model
- Explainable Boosting Machine

比較目的：

評估本研究模型是否能比傳統可解釋模型更好地捕捉非線性與時序變化特徵。

3. Black-box Machine Learning Baselines

此類模型代表常見高效能黑盒預測模型。

- Random Forest
- XGBoost
- LightGBM
- LSTM
- GRU

比較目的：

評估本研究模型是否能在預測效能上接近代表性黑盒模型，同時提供更好的本質可解釋性。

4. Ablation Study Baselines

此類模型用於驗證本研究各設計元件的貢獻。

- Randomly initialized FNN
- Guideline-guided FNN without temporal features
- Temporal FNN without clinical consistency regularization
- Full Knowledge-Guided Temporal FNN

比較目的：

分析 expert knowledge initialization、temporal feature design 與 clinical consistency regularization 是否各自對模型效能與規則品質有所貢獻。

十一、Evaluation Metrics

效能評估指標

本研究將從預測效能、校準度、可解釋性與臨床實用性四個面向進行評估。

1. Predictive Performance

用於評估模型是否能正確預測 SOFA Score Increase ≥ 2 。

- AUROC
- AUPRC
- Accuracy
- Sensitivity
- Specificity
- Precision
- F1-score

其中 AUPRC 對於不平衡資料特別重要，因為 ICU 病患惡化事件通常不是平均分布。

2. Calibration

用於評估模型輸出的風險機率是否可靠。

- Brier Score
- Expected Calibration Error
- Calibration Curve

在臨床應用中，模型不只要能排序病患風險高低，也需要讓輸出的風險機率具有可信度。

3. Interpretability and Rule Evaluation

用於評估模型輸出的 IF-THEN temporal fuzzy rules 是否簡潔、穩定且符合臨床邏輯。

- Rule Complexity
 - Rule Stability
 - Rule Concordance
 - Rule Drift
 - Number of activated rules
 - Average number of antecedents per rule
-

4. Clinical Utility

用於評估模型是否具有實際臨床應用價值。

- Lead Time Analysis
- Decision Curve Analysis
- Risk Stratification Performance
- Sensitivity at fixed specificity

Lead Time Analysis 將評估模型能否在 SOFA 分數明顯上升前數小時提前發出警訊。

Decision Curve Analysis 將評估模型在不同風險閾值下是否能提供臨床決策效益。

Risk Stratification Performance 將評估模型是否能將病患分成 low、medium、high risk 等不同風險層級。

十二、Expected Contributions

預期研究貢獻

本研究預期具有以下三項主要貢獻。

C1：提出以 SOFA Score Increase ≥ 2 為明確 Outcome 的 ICU 病患惡化早期預警模型

本研究明確將 ICU 病患惡化定義為未來 6、12、24 小時內 SOFA Score Increase ≥ 2 ，避免同時處理 mortality、vasopressor initiation、mechanical ventilation initiation 等多種異質 Outcome，進而建立更聚焦且可執行的研究設計。

C2：提出結合臨床知識初始化與 Clinical Consistency Regularization 的 Temporal Fuzzy Neural Network

本研究將 NEWS2 / SOFA 等臨床知識轉化為 membership functions、rule priors 與 clinical constraints，並進一步設計 Clinical Consistency Regularization，使模型在資料驅動訓練前即具備臨床邏輯基礎。

此設計可降低傳統 FNN 隨機初始化造成的不穩定性與不合理規則問題。

C3：建立 ICU 早期預警模型之 temporal fuzzy rule evaluation framework

本研究建立一套規則評估框架，用於量化 IF-THEN temporal fuzzy rules 的品質，包括：

- Rule Complexity
- Rule Stability
- Rule Concordance
- Rule Drift

此框架可用於評估模型輸出的規則是否簡潔、穩定、符合臨床知識，並分析模型訓練後是否適度調整或過度偏離原始臨床指引。

十三、Expected Research Value

預期研究價值

本研究希望跳脫傳統「疾病分類 + 模型準確率比較」的研究模式，改以 ICU 病患惡化早期預警作為核心問題，並透過 Fuzzy Neural Network 的本質可解釋能力，建立兼具預測效能、臨床邏輯一致性與規則透明度的模型。

相較於單純黑盒模型，本研究模型可同時提供：

1. 病患未來 6、12、24 小時內 SOFA Score Increase ≥ 2 的風險機率
2. 可理解的 IF-THEN temporal fuzzy rules
3. 具時間語意的病情變化描述
4. 與 NEWS2 / SOFA 臨床知識一致的推理基礎
5. 可量化評估的規則品質指標